Ávore de Decisão

Mini-projeto 2 - Sistemas Inteligentes

Prof. Germano Crispim Vasconcelos

Equipe 6

- Alice Oliveira aoqb
- Ana Albuquerque alas3
- Enrique Laborão elm2
- · Victória Luisi vIsc
- · Olivia Tavares obtmc

Setup

Importando dependências, conectando Google Drive, lendo datasets e criando os respectivos dataframes.

Dependências

```
In [ ]:
```

```
import numpy as np
import pandas as pd

import matplotlib.pyplot as plt
import seaborn as sns

from sklearn.ensemble import RandomForestClassifier
from sklearn.tree import DecisionTreeClassifier, plot_tree
from sklearn.model_selection import train_test_split, GridSearchCV
from sklearn.metrics import classification_report, accuracy_score, precision_score, rec
all_score, f1_score, roc_auc_score, confusion_matrix
```

Drive

```
In [ ]:
```

```
from google.colab import drive
drive.mount('/content/drive')
base_path = '/content/drive/MyDrive/'
```

Mounted at /content/drive

Titanic Dataset - https://www.kaggle.com/c/titanic/data (https://www.kaggle.com/c/titanic/data)

```
In [ ]:
```

```
titanic_train_dataset_path = base_path + 'titanic/train.csv'
titanic_test_dataset_path = base_path + 'titanic/test.csv'
```

Lower Back Pain Symptoms Dataset - https://www.kaggle.com/datasets/sammy123/lower-back-pain-symptoms-dataset)

```
In [ ]:
```

```
pain_dataset_path = base_path + 'Dataset_spine.csv'
```

Lendo datasets

```
In [ ]:
```

```
titanic_df = pd.read_csv(titanic_train_dataset_path)
titanic_test_df = pd.read_csv(titanic_test_dataset_path) # Não possui a coluna de class
ificação (Survived)
```

In []:

```
pain_df = pd.read_csv(pain_dataset_path)
pain_df = pain_df.drop(pain_df.columns[[13]], axis=1) # Removendo a coluna 13
```

Funções

In []:

```
def predict_and_report(title, classifier, x_test, y_test, y_train, x_train):
    y_pred = classifier.predict(x_test)
    report = classification_report(y_test, y_pred)
    print(title + "- base de teste")
    print(report)
    plot_confusion_matrix(y_test, y_pred)
    print("------")
    y_pred = classifier.predict(x_train)
    report = classification_report(y_train, y_pred)
    print(title + "- base de treino")
    print(report)
```

```
def plot_confusion_matrix(y_test, y_pred):
    cm = confusion_matrix(y_test, y_pred)
    fig, ax = plt.subplots(figsize=(2,2))
    sns.heatmap(cm, annot=True, fmt='d')
```

🚅 Projeto: Titanic Dataset



🔎 Análise e limpeza do Dataset

Valores faltantes

A primeira análise feita é verificar os valores faltantes. Três colunas possuem valores nulos: Age, Cabin e Embarked. Cada coluna terá um tratamento apropriado.

```
In [ ]:
titanic df.shape
Out[ ]:
(891, 12)
In [ ]:
#titanic df.info()
titanic_df.isnull().sum()
Out[ ]:
PassengerId
                  0
Survived
                  a
Pclass
                  0
Name
                  0
Sex
Age
                177
SibSp
                  0
```

Age

Parch

Fare

Cabin

Embarked dtype: int64

Ticket

0

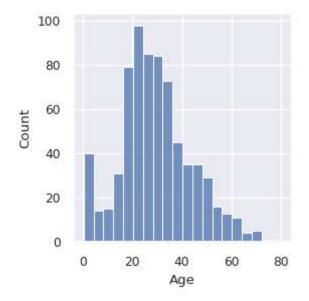
0

0

687

- Como é uma coluna de valores numéricos, que a maioria dos valores não é nulo e que acreditamos ter grande relevância para a sobrevivência ou não, será utilizado um método de substituir os valores nulos por um outro valor.
- No plot vemos que se aproxima de uma distribuição assimétrica para a direita, então, então podemos substituir os valores faltantes pela mediana. [1] (https://vitalflux.com/pandas-impute-missing-valuesmean-median-mode/#How to decide which imputation technique to use)
- ldealmente, deveríamos analisar a correlação entre a idade e outras features, observando a existência de uma correlação, então os valores nulos deveriam ser substituídos pela mediana do subconjunto (separado pelas outras features correlacionadas). Não fizemos isso por não achar necessário para o escopo do projeto.

```
sns.set(font_scale=0.8)
sns.displot(titanic_df['Age'], height=3)
plt.show()
```



In []:

```
titanic_df['Age'] = titanic_df['Age'].fillna(titanic_df['Age'].median())
```

Cabin

- A maioria dos valores são nulos (687 de 891), não são numéricos e possuem muitos valores únicos.
- Poderia ser feita uma tentativa de extrair informações relevantes dos dados que existem, visto que as strings consistem de uma letra seguida por um ou dois números, podemos deduzir que está relacionada a posição da cabine no navio, podendo então influenciar na sobrevivência de um passageiro. [2] (https://www.kaggle.com/code/ccastleberry/titanic-cabin-features/notebook)
- Entretanto, optaremos por descartar a coluna devido a quantidade de valores faltantes.

```
titanic_df['Cabin'].value_counts()
Out[ ]:
B96 B98
                4
                4
G6
C23 C25 C27
                4
C22 C26
                3
                3
F33
E34
                1
C7
                1
C54
                1
E36
                1
                1
C148
Name: Cabin, Length: 147, dtype: int64
```

```
In [ ]:
titanic_df = titanic_df.drop(columns=['Cabin'])
```

Embarked

• Como se tratam de valores categóricos, os dois valores faltantes serão subsituídos pela moda.

```
In [ ]:
titanic_df['Embarked'].value_counts()
Out[]:
S
     644
C
     168
      77
Name: Embarked, dtype: int64
In [ ]:
titanic_df['Embarked'] = titanic_df['Embarked'].fillna(titanic_df['Embarked'].mode()
[0])
In [ ]:
titanic_df['Embarked'].value_counts()
Out[ ]:
S
     646
C
     168
      77
Name: Embarked, dtype: int64
```

Colunas consideradas irrelevantes

Algumas colunas possuem informações irrelevantes: identificadores que não apresentam relação direta com algo que possa definir a sobrevivência ou são valores aleatórios:

- Passengerld
- Ticket

```
In [ ]:
```

```
titanic_df = titanic_df.drop(columns=['PassengerId'])
titanic_df = titanic_df.drop(columns=['Ticket'])
```

Substituição dos valores categóricos por numéricos

Name

- Essa coluna é composta apenas de valores únicos, mas todos os indivíduos possuem títulos (Mr., Mrs., Miss., etc).
- É possível extrair a informação do título do passageiro e criar uma nova coluna.

```
In [ ]:
```

```
titanic df['Name'].unique().size
Out[ ]:
891
In [ ]:
titles = titanic_df.Name.str.extract(' ([A-Za-z]+)\.', expand=False)
print(titles.size)
titles.value_counts()
891
Out[ ]:
Mr
            517
Miss
             182
Mrs
             125
              40
Master
Dr
               7
Rev
               6
Mlle
               2
               2
Major
               2
Col
Countess
               1
Capt
               1
Ms
               1
Sir
               1
Lady
               1
Mme
               1
Don
               1
Jonkheer
               1
```

- Como Mr, Miss, Mrs e Master são os únicos títulos que se repetem mais de dez vezes, vamos optar por substituir o restante por 'Other'. E outros títulos que equivalem a esses títulos também serão subsituídos.
- O seguinte mapeamento será feito:

Name: Name, dtype: int64

■ Mr = 0, Mrs = 1, Miss = 2, Master = 3, Other = 4

```
In [ ]:
titles = titles.replace(['Lady', 'Countess','Capt', 'Col', 'Don', 'Dr', 'Major', 'Rev',
'Sir', 'Jonkheer', 'Dona'], 'Other')
titles = titles.replace('Mlle', 'Miss')
titles = titles.replace('Ms', 'Miss')
titles = titles.replace('Mme',
                                'Mrs')
titles = titles.map({"Mr": 0, "Mrs": 1, "Miss": 2, "Master": 3, "Other": 4})
titles.value_counts()
Out[ ]:
0
     517
2
     185
1
     126
3
      40
      23
4
Name: Name, dtype: int64
In [ ]:
titanic df = titanic df.drop(columns=['Name'])
In [ ]:
titanic_df['Title'] = titles
Outras colunas
In [ ]:
titanic_df['Sex'].unique()
Out[ ]:
array(['male', 'female'], dtype=object)
In [ ]:
titanic_df['Embarked'].unique()
Out[ ]:
array(['S', 'C', 'Q'], dtype=object)
Antes de treinar o modelo, é necessário converter algumas colunas de uma string para um valor numérico.
 • Sex (male = 0, female = 1)
 • Embarked (S = 0, C = 1, Q = 2)
In [ ]:
titanic_df['Sex'] = titanic_df['Sex'].map({'male': 0, 'female': 1})
In [ ]:
titanic_df['Embarked'] = titanic_df['Embarked'].map({'S': 0, 'C': 1, 'Q': 2})
```

Combinar colunas

- Podemos combinar as colunas Sibsp e Parch para ter uma coluna representando o tamanho da família.
- Fizemos alguns testes combinando as colunas e não houve melhoria significativa nos scores.

In []:

```
#family = titanic_df['SibSp'] + titanic_df['Parch']
#titanic_df['Family'] = family
```

In []:

```
#titanic_df = titanic_df.drop(columns=['SibSp', 'Parch'])
```

Dataset após limpeza

In []:

```
titanic df.info()
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 891 entries, 0 to 890
Data columns (total 9 columns):
#
    Column
              Non-Null Count
                              Dtype
    -----
              -----
0
    Survived 891 non-null
                              int64
   Pclass
1
            891 non-null
                              int64
    Sex
 2
              891 non-null
                              int64
 3
              891 non-null
                              float64
    Age
              891 non-null
 4
   SibSp
                              int64
5
   Parch
              891 non-null
                              int64
 6
    Fare
              891 non-null
                              float64
7
    Embarked 891 non-null
                              int64
    Title
              891 non-null
                              int64
dtypes: float64(2), int64(7)
memory usage: 62.8 KB
```

X Criando modelo

In []:

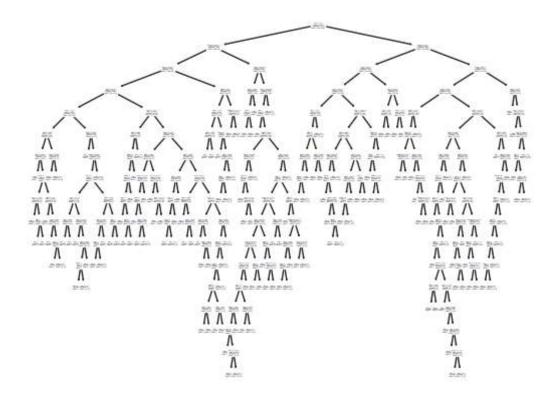
```
titanic_x = titanic_df.drop(columns=['Survived'])
titanic_y = titanic_df['Survived']

titanic_x_train, titanic_x_test, titanic_y_train, titanic_y_test = train_test_split(titanic_x, titanic_y, test_size = 0.2)
```

1. Classificador com parâmetros default

```
classifier1 = DecisionTreeClassifier()
classifier1.fit(titanic_x_train, titanic_y_train)
```

```
plot_tree(classifier1, feature_names=titanic_df.drop(columns=['Survived']).columns)
plt.show()
```



In []:

```
titanic_y_pred = classifier1.predict(titanic_x_test)
titanic_report = classification_report(titanic_y_test, titanic_y_pred)
print(titanic_report)
```

	precision	recall	f1-score	support
0	0.79	0.85	0.82	105
1	0.76	0.68	0.71	74
accuracy			0.78	179
macro avg	0.77	0.76	0.77	179
weighted avg	0.78	0.78	0.77	179

2. Utilizando GridSearchCV

```
parameters1 = {
    'criterion': ["gini", "entropy", "log_loss"],
    'splitter': ["best", "random"],
    'max_depth': [3, 10, 30, None],
    'max_features': ["sqrt", "log2", None],
    'min_samples_split': [2, 16, 32],
    'max_leaf_nodes': [5, 10, 40, None],
    'random_state': [13]
}
```

```
grid = GridSearchCV(estimator = DecisionTreeClassifier(), param_grid = parameters1)
grid.fit(titanic_x_train, titanic_y_train)
```

In []:

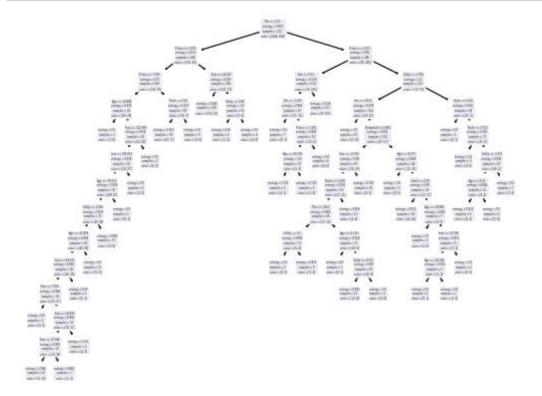
```
print(grid.best_score_)
print(grid.best_params_)
```

0.8385403329065302

```
{'criterion': 'entropy', 'max_depth': 30, 'max_features': None, 'max_leaf_
nodes': 40, 'min_samples_split': 2, 'random_state': 13, 'splitter': 'rando
m'}
```

In []:

```
plot_tree(classifier2, feature_names=titanic_df.drop(columns=['Survived']).columns)
plt.show()
```



```
titanic_y_pred = classifier2.predict(titanic_x_test)
titanic_report = classification_report(titanic_y_test, titanic_y_pred)
print(titanic_report)
```

	precision	recall	f1-score	support
0	0.82	0.90	0.85	105
1	0.83	0.72	0.77	74
accuracy			0.82	179
macro avg	0.82	0.81	0.81	179
weighted avg	0.82	0.82	0.82	179

3. Tentando obter uma árvore menor com score similar

In []:

```
parameters2 = {
    'criterion': ["gini", "entropy", "log_loss"],
    'splitter': ["best", "random"],
    'max_depth': [2, 4, 6],
    'max_features': ["sqrt", "log2", None],
    'min_samples_split': [2, 4, 8],
    'max_leaf_nodes': [4, 7, 10],
    'random_state': [13]
}
```

In []:

```
grid2 = GridSearchCV(estimator = DecisionTreeClassifier(), param_grid = parameters2)
grid2.fit(titanic_x_train, titanic_y_train)
```

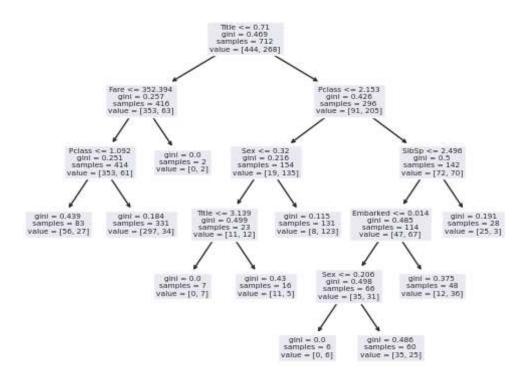
In []:

```
print(grid2.best_score_)
print(grid2.best_params_)
```

0.8357234314980794

```
{'criterion': 'gini', 'max_depth': 6, 'max_features': None, 'max_leaf_node
s': 10, 'min_samples_split': 2, 'random_state': 13, 'splitter': 'random'}
```

plot_tree(classifier3, feature_names=titanic_df.drop(columns=['Survived']).columns)
plt.show()



In []:

```
titanic_y_pred = classifier3.predict(titanic_x_test)
titanic_report = classification_report(titanic_y_test, titanic_y_pred)
print(titanic_report)
```

	precision	recall	f1-score	support
0	0.80	0.94	0.87	105
1	0.89	0.68	0.77	74
accuracy			0.83	179
macro avg	0.85	0.81	0.82	179
weighted avg	0.84	0.83	0.83	179

Utilizando Random Forests

Aplicando o RandomForestClassifier com a configuração default no problema Titanic.

```
In [ ]:
```

```
parameters3 = {
    'criterion': ["gini", "entropy", "log_loss"],
    'n_estimators': [10, 50, 100], # Novo
    'max_depth': [2, 4, 6],
    'max_features': ["sqrt", "log2", None],
    'min_samples_split': [2, 4, 8],
    'max_leaf_nodes': [4, 7, 10],
    'random_state': [13]
}
```

```
grid3 = GridSearchCV(estimator = RandomForestClassifier(), param_grid = parameters3)
grid3.fit(titanic_x_train, titanic_y_train)
```

In []:

```
print(grid3.best_score_)
print(grid3.best_params_)
```

0.8413473850093569

```
{'criterion': 'gini', 'max_depth': 6, 'max_features': 'sqrt', 'max_leaf_no
des': 10, 'min_samples_split': 4, 'n_estimators': 10, 'random_state': 13}
```

In []:

```
titanic_y_pred = classifier4.predict(titanic_x_test)
titanic_report = classification_report(titanic_y_test, titanic_y_pred)
print(titanic_report)
```

	precision	recall	f1-score	support
0	0.82	0.92	0.87	105
1	0.87	0.72	0.79	74
accuracy			0.84	179
macro avg	0.85	0.82	0.83	179
weighted avg	0.84	0.84	0.83	1 79

🐣 Utilizando AD no problema de Detecção de Lombalgia

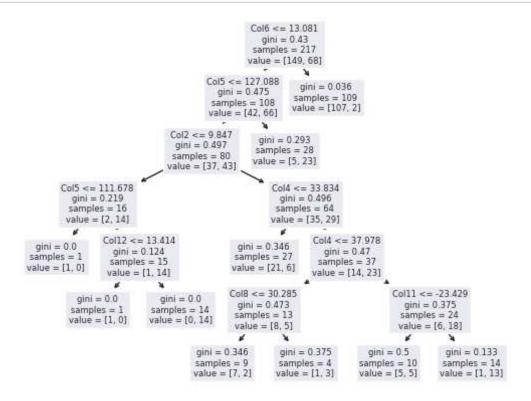
In []:

```
pain_x = pain_df.drop(columns=['Class_att'])
pain_y = pain_df['Class_att']

pain_x_train, pain_x_test, pain_y_train, pain_y_test = train_test_split(pain_x, pain_y, test_size = 0.3)
```

In []:

```
plot_tree(classifier5, feature_names=pain_df.drop(columns=['Class_att']).columns)
plt.show()
```



```
pain_y_pred = classifier5.predict(pain_x_test)
pain_report = classification_report(pain_y_test, pain_y_pred)
print(pain_report)
```

	precision	recall	f1-score	support
Abnormal Normal	0.81 0.79	0.92 0.59	0.86 0.68	61 32
accuracy			0.81	93
macro avg	0.80	0.76	0.77	93
weighted avg	0.80	0.81	0.80	93



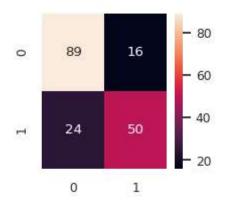
Titanic

• Configuração padrão teve os menores scores e houve overfitting.

predict_and_report("AD - Configuração padrão", classifier1, titanic_x_test, titanic_y_t
est, titanic_y_train, titanic_x_train)

AD - Configu	ração padrão-	base de	teste	
	precision	recall	f1-score	support
0	0.79	0.85	0.82	105
1	0.76	0.68	0.71	74
accuracy			0.78	179
macro avg	0.77	0.76	0.77	179
weighted avg	0.78	0.78	0.77	179
macro avg			0.77	179

AD - Configur			treino f1-score	support
0	0.98	1.00	0.99	444
1	0.99	0.96	0.98	268
accuracy			0.98	712
macro avg	0.98	0.98	0.98	712
weighted avg	0.98	0.98	0.98	712



• Configuração 1 teve melhoria nos scores.

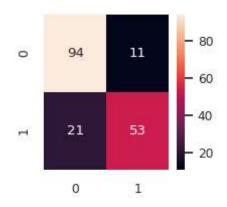
```
print(grid.best_params_)
```

```
{'criterion': 'entropy', 'max_depth': 30, 'max_features': None, 'max_leaf_
nodes': 40, 'min_samples_split': 2, 'random_state': 13, 'splitter': 'rando
m'}
```

predict_and_report("AD - Configuração 1", classifier2, titanic_x_test, titanic_y_test, titanic_y_train, titanic_x_train)

AD - Configur	ação 1- base	de teste		
	precision	recall	f1-score	support
0	0.82	0.90	0.85	105
1	0.83	0.72	0.77	74
accuracy			0.82	179
macro avg	0.82	0.81	0.81	179
weighted avg	0.82	0.82	0.82	179

AD - Con-	figur	ação 1- bas	e de treir	10	
		precision	recall	f1-score	support
	0	0.88	0.93	0.90	444
	_				
	1	0.87	0.78	0.83	268
accui	racy			0.88	712
macro	avg	0.87	0.86	0.86	712
weighted	avg	0.87	0.88	0.87	712



• Configuração 2 teve scores similares (mas é uma árvore consideravelmente menor)

```
print(grid2.best_params_)
```

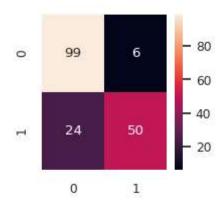
```
{'criterion': 'gini', 'max_depth': 6, 'max_features': None, 'max_leaf_node
s': 10, 'min_samples_split': 2, 'random_state': 13, 'splitter': 'random'}
```

In []:

predict_and_report("AD - Configuração 2", classifier3, titanic_x_test, titanic_y_test,
titanic_y_train, titanic_x_train)

AD - Configuração 2- base de teste precision recall f1-score support 0 0.80 0.94 105 0.87 1 0.89 0.68 74 0.77 0.83 179 accuracy macro avg 0.85 0.81 0.82 179 0.83 weighted avg 0.84 0.83 179

AD - Configur	ação 2- base	de trein	О	
	precision	recall	f1-score	support
0	0.82	0.95	0.88	444
1	0.90	0.65	0.75	268
accuracy			0.84	712
macro avg	0.86	0.80	0.82	712
weighted avg	0.85	0.84	0.83	712



• RF apresentou scores similares.

In []:

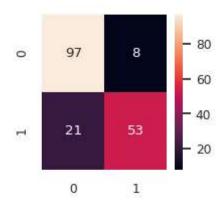
predict_and_report("RF - Configuração 1", classifier4, titanic_x_test, titanic_y_test,
titanic_y_train, titanic_x_train)

RF - Configuração 1- base de teste

	precision	recall	f1-score	support
0	0.82	0.92	0.87	105
1	0.87	0.72	0.79	74
accuracy			0.84	179
macro avg	0.85	0.82	0.83	179
weighted avg	0.84	0.84	0.83	179

RF - Configuração 1- base de treino

	precision	recall	f1-score	support
0	0.84	0.93	0.88	444
1	0.86	0.71	0.78	268
accuracy			0.85	712
macro avg	0.85	0.82	0.83	712
weighted avg	0.85	0.85	0.84	712



Detecção de Lombalgia

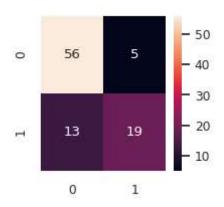
In []:

predict_and_report("AD - Configuração 1", classifier5, pain_x_test, pain_y_test, pain_y_train, pain_x_train)

AD - Configuração 1- base de teste				
_	precision	recall	f1-score	support
Abnormal	0.81	0.92	0.86	61
Normal	0.79	0.59	0.68	32
accuracy			0.81	93
macro avg	0.80	0.76	0.77	93
weighted avg	0.80	0.81	0.80	93
AD - Configuração 1- base de treino				
	precision	recall	f1-score	support
Abnormal	0.90	0.95	0.93	149
Normal	0.88	0.78	0.83	68
accuracy			0.90	217
macro avg	0.89	0.87	0.88	217

0.90

0.90



weighted avg

- Acurácia com MLP: 0.82
- Acurácia com AD (configuração 2): 0.81
- Testando outras configurações considerando esse dataset poderíamos obter resultados melhores.

0.90

217